

Assignment 3 report

2022873005 김하늘

1. Problem 1: Exploration of Marabou Resources

- 1) 모델 : .nnet, .onnx 등의 포맷이 있고 항공기 충돌 방지 시스템인 ACAS Xu와 MNIST, CIFAR10 모델들을 확인할 수 있었다.
- 2) Datasets : 예를 들어 ACAS Xu의 센서 데이터 범위는 텍스트 파일이나 스크립트로 돼있습니다. 검증하기 위한 입력 변수의 범위가 나타나 있는 것을 확인할 수 있었다.
- 3) Example queries : .vnnlib에서 입력 범위를 제약하는 것을 볼 수 있고, Marabou 쿼리 예시도 볼 수 있습니다. 이로서 L_∞ Robustness 테스트 방법을 알아볼 수 있다.

2. Implementation & Results

2.1 Model & Dataset Selection

- 1) Model: TinyMNIST
- 2) Dataset: MNIST Handwritten Digits
- 3) Reason: 연산을 효율적으로 할 수 있는 작은 모델을 직접 설계했으며 현실적인 MNIST분류 문제의 보안적인 부분의 취약한 부분을 확인하고자 하였다.

2.2 Modifications for Compatibility

- 1) 최신의 PyTorch 환경에서 호환성부분을 위해 onnxscript 라이브러리를 추가하여 모델 export를 하는 것을 안정화했다.
- 2) maraboupy의 solve함수가 3개(exitCode, vals, stats)를 반환할 수 있도록하는 구조로 코드를 수정하였다
- 3) Numpy 배열 형태의 변수를 Marabou가 인식하지 못하는 오류를 방지하기 위해 .item()을 사용하여 순수 파이썬 데이터 타입으로 변환하였다.
- 4) 라이브러리 버전마다 다른 통계 데이터(stats) 구조 때문에 예외 처리를 적용해서 검증이 중단되지 않고 완료할 수 있도록 했다.

2.3 Verification Query Formulation

- 1) Input Constraint : 픽셀의 기준값을 0.5로 하고 L_∞ 노이즈를 0.01 적용했다. 그래서 각 픽셀은 [0.49, 0.51] 범위를 가진다.
- 2) Output Property: Class 0으로 분류되어야 할 상황에서 Class 1의 점수가 더 높아지는 경우가 존재하는지 보고 오분류를 내게하는 지점이 존재하는지 본다. (Output[1] - Output[0] > 0)

2.4 Verification Results

1) Result: SAT

2) Runtime: < 1s

(모델이 작아서 검증이 금방 완료됐고 시스템 출력 로그를 통해 안정적인 검증 수행이 됨)

3) Counterexample Found: 모든 입력 픽셀이 0.49로 변했을 때 클래스 간 점수 역전이 발생했다.

3. Analysis & Discussion

3.1 Results & Interpretation

1%의 작은 변화만으로 모델이 오작동하는 것이 발견됐다. 출력값을 분석한 결과 다음과 같다.

클래스	점수 (Logit)	순위
output 2	0.1928	1위 (가장 높음)
output 9	0.1000	2위
output 0	-0.1963	(낮음)
output 1	-0.3840	(가장 낮음)

Output[1] > Output[0] 를 확인했는데 반례에서는 Class 2의 점수가 가장 높았다. 입력값을 아주 조금 바꿨을 때 모델이 전혀 다른 숫자인 2로 오분류하는 곳을 Marabou가 찾아냈다. 모든 픽셀이 0.49로 낮아질 때 SAT가 발생했고 이로서 모델이 이미지의 전체적인 밝기 변화나 특정 방향의 노이즈에 취약하다는 것을 알 수 있다.

3.2 Strengths & Limitations of Marabou

1) Strengths : 수학적으로 모든 가능성을 봐서 UNSAT 결과도출할 때 해당 범위 내에서 절대적인 강건성을 보장할 수 있다. maraboupy API를 통해 복잡한 SMT 공식을 작성하지 않고도 검증 쿼리를 만들 수 있다.

2) Limitations: 모델 깊이가 깊어지거나 레이어가 복잡해질수록 변수와 제약 조건이 많이 늘어나 검증 시간이 기하급수적으로 증가한다. 특정 연산자나 최신 레이어 구조의 경우 연동 과정에서 세밀한 전처리를 해야한다.

```
output 0 = -0.19639111046194974
output 1 = -0.38401440777448415
output 2 = 0.192811771431122
output 3 = 0.02850235933934455
output 4 = -0.25613720079026686
output 5 = 0.08550010081498147
output 6 = 0.09877968975051196
output 7 = -0.004356209246730142
output 8 = -0.22866445829718524
output 9 = 0.10004325133846614

=== Result: SAT ===
A counterexample was found. The network is NOT robust.
Counterexample first 5 pixels: [0.49, 0.49, 0.49, 0.49, 0.49]

Verification Statistics:
Statistics retrieved, but time format is different.
```